

9. Reprezentace čísel a základní dvojkové aritmetické operace (doplňkové kódy, pevná a plovoucí řádová čárka, IEEE 754)

9. Reprezentace čísel a binární aritmetika

SZZ okruh 9 (FIT BUT). Rozsah čísel je omezen **počtem bitů** (short int 16 b, int 32 b, long 64 b).

Shrnutí

Celá čísla se znaménkem

- **Přímý kód** — první bit znaménko; problém **dvojí nuly**, komplikuje sčítání/odčítání.
- **Aditivní kód (posunutá nula)** — číslo posunuté o konstantu (využití v exponentu IEEE 754).
- **Jedničkový doplněk** — záporné = negace bitů; opět dvojí nula.
- **Dvojkový doplněk** — záporné = negace + 1; **jediná nula**, sčítání/odčítání **stejně jako bez znaménka** □ nejpoužívanější.

Desetinná čísla

- **Pevná řádová čárka** — pevný počet bitů na celou a desetinnou část; dnes vzácné.
- **Plovoucí řádová čárka (IEEE 754)** — znaménko **S**, **mantisa** **M** (přímý kód, implicitní 1), exponent **E** (kód s posunutou nulou), základ 2.
 - **single (float, 32 b)** — exponent 8 b (posun □127), mantisa 23 b, přesnost ~7 dekadických číslic.
 - **double (64 b)** — exponent 11 b (posun □1023), mantisa 52 b, přesnost ~16 číslic.

[[media/szz-09/media/image11.png]] *IEEE 754 (single): interpretace hodnot podle exponentu — normalizovaná/denormalizovaná čísla, ±0, ±□, NaN.*

[!note] Ke kontrole (ověřeno proti standardu IEEE 754) Plné znění uvádí u **single** rozlišitelnost normalizovaných 2^{-127} a nenormalizovaných 2^{-150} a u **double** $2^{-1023} / 2^{-1075}$ — všechny jsou **o jedničku posunuté**. Správně: single nejmenší normalizované = 2^{-126} , nejmenší denormalizované = 2^{-149} ; double $2^{-1022} / 2^{-1074}$. Rozsah „ $\langle -2^{127}, 2^{127} \rangle$ ” je také přibližný — největší konečné single □ 2^{128} .

- **Chyba zobrazení** — např. 0,1 nelze přesně vyjádřit; pro finance se používá **BCD** nebo **fixní řád** (uložení celého čísla setin).

Aritmetické operace

- **Sčítání** — celočíselné jako v desítkové soustavě; přetečení □ **OF** (signed) / **CF** (unsigned). Floating point **není asociativní** (zaokrouhlovací chyby); nutno převést na společný exponent.

- **Odčítání** — bitová negace + sčítání s $C0 = 1$.
- **Násobení** — výsledek až $2\times$ širší; u doplňkového kódu nutno **rozšířit MSB** (znaménko). IEEE 754: znaménko = XOR, exponenty se sčítají, mantisy se násobí.
- **Dělení** — náročné (např. bez restaurace zbytku, SRT).

[[media/szz-09/media/image6.png]] Sčítání čísel v plovoucí řádové čárce — zarovnání na společný exponent.

Souvislosti

Sčítačky realizující tyto operace popisuje [[okruhy/02-kombinacni-logicke-obvody]]; převody mezi soustavami viz [[okruhy/18-ciselne-soustavy]].

Časté otázky u zkoušky

Na co se u tohoto okruhu typicky ptají. Plné odpovědi níže.

Reprezentace čísel □ [[#Desetinná čísla]] - *Fixed vs. floating point?* □ Pevná: pevný počet bitů na celou/desetinnou část (omezený rozsah); plovoucí: mantisa $\times 2^{\text{exponent}}$ (velký rozsah, omezená přesnost). - *Struktura IEEE 754?* □ sign bit + exponent (s BIASem) + mantisa (implicitní 1); single 32 b (E 8 b, M 23 b, bias 127), double 64 b (E 11 b, bias 1023). - *Co je BIAS?* □ Posun exponentu (kód posunutě nuly) □ umožní záporné exponenty bez znaménkového bitu.

Kódy záporných čísel □ [[#Celá čísla se znaménkem]] - *Přímý / jedničkový / dvojkový doplněk?* □ Přímý (znaménkový bit, dvojitá nula); jedničkový doplněk (negace bitů, dvojitá nula); dvojkový doplněk (negace + 1, jediná nula □ nejpoužívanější, sčítání/odčítání jako bez znaménka). - *Proč nejmenší záporné nelze invertovat?* □ Jeho kladný protějšek se nevejde do rozsahu (asymetrie doplňkového kódu).

Aritmetické operace □ [[#Aritmetické operace]] - *Kdy je výsledek zobrazitelný / přetečení?* □ signed □ overflow flag (OF); unsigned □ carry flag (CF). - *FP sčítání a normalizace?* □ Zarovnat na společný (větší) exponent, sečíst mantisy, normalizovat; FP sčítání není asociativní (zaokrouhlení). - *Proč nelze přesně 0,1?* □ Není konečným součtem mocnin 2 □ pro finance BCD / fixní řád.

Plné znění (ke studiu)

Čísla jsou v počítačích reprezentována hodnotami jednotlivých bitů - **binárně**, tedy ve **dvojkové soustavě**. Narozdíl od reálného světa je rozsah čísel omezen **počtem bitů**, které jsou pro číslo vyhrazeny. Dnes jsou obvykle používány tři číselné rozsahy, které mohou být **znaménkové** i **bez znaménka**, jsou to:

- **short int** - 16 bitů,
- **integer** - 32 bitů,
- **long int** - 64 bitů.

Reprezentace celých čísel se znaménkem

Reprezentace znaménka vždy sníží rozsah **absolutní** hodnoty čísla na **polovinu**, nicméně umožňuje reprezentovat **záporná čísla** a **celkový počet** čísel se tak **nezmění** (až na dvojitou nulu). Reprezentace znaménka je realizována následovně:

- **Přímý kód**: **První bit** je rezervován pro znaménko (**1** pro **záporná**, **0** pro **kladná**). Existují zde však **2 nuly** (+0 a -0). Použití například v IEEE754. (10000001 = -1). Kód **komplikuje** algoritmy pro **sčítání**, **odčítání** i **násobení**, nutnost testovat na znaménko. Dalším problémem je existence **dvojitých nul**.

- **Aditivní kód (kód s posunutou nulou):** Číslo je posunuté o nějakou danou konstantu (Např. $-127 = 00000000$; $128 = 11111111$; $1 = 10000000$; $0 = 01111111$ - viz IEEE 754; $-1 = 01111110$...). **Nevýhodou** je, že reprezentace kladných znaménkových čísel se **liší** od neznaménkových, a při **násobení** se musí odečítat určená konstanta. Sčítání lze provádět normálně.
- **Jedničkový doplněk** (inverzní kód): Záporná hodnota se získá **znegováním** všech bitů kladného čísla (MSB musí být u **kladných** vždy **0** a u **záporných** vždy **1**). Např. $0101 = 5$, $1010 = -5$, $0000 = 0$, $1111 = -0$. Kód **komplikuje** algoritmy pro **sčítání** a **odčítání** (jiné než u čísel bez znaménka) i **násobení**. Dalším problémem je existence **dvojí** nuly.
- **Dvojkový doplněk** (doplňkový kód): Kladné číslo je reprezentováno normálně, záporné však je **inverzí** kladného čísla a **přičtením 1**. **Nejpoužívanější** formát. Pouze jedna reprezentace 0. ($11111111 = -1$). Sčítání a odčítání lze realizovat **stejně** jako s neznaménkovými čísly, u násobení je nutné **replikovat** (nakopírovat) původní **MSB** na **dvojnásobný** rozsah čísla na všechny následující pozice až po nový MSB, aby nedošlo ke změně znaménka po operaci.

Reprezentace desetinných čísel

Umožňují reprezentovat reálná čísla s omezenou přesností.

Pevná řádová čárka

Pro zobrazení kladných reálných čísel. **Přesný počet** bitů je rezervováno pro **celou** část a **zbytek** pro **desetinnou** část čísla. Dnes se skoro nevyužívá. Např. 5 číslic pro celou část a 3 číslice pro desetinnou, **00101001 = 5.125**.

Plovoucí řádová čárka (Floating point) - IEEE 754

Číslo je reprezentováno:

- **znaménkovým bitem** (*S*) - MSB - **1** znamená záporný, **0** kladný,
- **mantisou** (*M*) - v přímém kódu, obsahuje **implicitní 1**,
- **základem** (*B*) - je implicitní, rovna číslu **2**,
- **exponentem** (*E*) - v kódu posunutá nula, což umožňuje vyjádřit záporný exponent.

IEEE 754 definuje uložení čísla v plovoucí řádové čárce jako MSB je znaménkový bit, následují bity exponentu a poté až bity mantisy. Definovány jsou dvě reprezentace lišící se přesností a rozsahem čísla.

- **Single precision** (float - 32 bitů): Exponent má rozsah **8** bitů a je posunut o **-127** (polovinu rozsahu, 0 a 255 v exponentu představují speciální hodnoty; exponent je roven 0, pokud je jeho hodnota 127 binárně), mantisa je vyjádřena na **23** bitech, MSB je znaménkový. **Přesnost** je **7** dekadických čísel, rozsah zobrazení je $\langle -2^{127}, 2^{127} \rangle$, rozlišitelnost **normalizovaných** čísel je 2^{-127} a **nenormalizovaných** 2^{-150} . Největší a **druhé** největší číslo se liší o 2^{104} (23 jedniček $\ll 127 - (22 \text{ jedniček a } 0) \ll 127 = 2^{104}$).

[[media/szz-09/media/image11.png]]

[[media/szz-09/media/image3.png]]

- **Double precision** (double - 64 bitů): Exponent má rozsah **11** bitů a je posunut o **-1023** (polovinu rozsahu), mantisa je vyjádřena na **52** bitech, MSB je znaménkový. **Přesnost** je **16** dekadických čísel, rozsah zobrazení je $\langle -2^{1023}, 2^{1023} \rangle$, rozlišitelnost **normalizovaných** čísel je 2^{-1023} a **nenormalizovaných** 2^{-1075} .

Explicitní jednička - V mantise čísla je nutné explicitně mít jedničku. [[media/szz-09/media/image7.png]]

Implicitní jednička - Umožňuje zvýšit rozsah reprezentovaného čísla o jeden bit, v mantise se jednička neuvádí. Až na **denormalizované** čísla se s ní pracuje implicitně - **1.011** -> **011**.

Chyba zobrazení

Jelikož se číslo skládá ze **součtu zlomků** mocnin 2 (např. $2^{-2} = \frac{1}{4}$) **není** možné na konečném počtu bitů (registru) **reprezentovat** všechna čísla, a tak dochází k **nepřesnostem**. Např. číslo **0.1** nelze přesně vyjádřit, což je obvyklá hodnota ve finančnictví a je nutné pro tyto aplikace používat jiné kódování čísel. Používá se **BCD (Binary Coded Decimal) kód**

- Každá dekadická číslice je zobrazena v jednom niblu (4 bitech bytu). Znaménko může být v prvním bitu. 01000010 = 42.

Další nepřesnosti vznikají při sčítání/odčítání čísel, která jsou od sebe **řádově** vzdálená, mají **výrazně** rozdílný exponent (menší číslo může být úplně ignorováno).

Fixní řád

- Čísla se ukládají jako celá s předem definovaným počtem desetinných míst. Např. 0,1 Kč = 10 setin -> uložíme jako integer 10
123,45 Kč -> 12345
- Pak při získávání hodnoty pouze podělíme /100
- **Nevýhoda:** Náchylné na chyby -> využívat getters a setters pro získávání a nastavování hodnoty
- **Výhoda:** Mnohem rychlejší než práce s floaty

Matematické operace

Sčítání

- **Celočíselné** sčítání se provádí stejně jako v 10 soustavě. V případě sčítání v procesoru může dojít k **přetečení** (součet se nevejde do podporovaného rozsahu)
-> nastavení **overflow flag** (OF) pro signed, **carry flag** (CF) pro unsigned.

[[media/szz-09/media/image4.png]]

- **Floating point** sčítání není **asociativní** vlivem **zaokrouhlovacích** chyb. V **IEEE 754** se u sčítání musí nejdříve převést obě čísla na **stejný exponent**. Vždy se převádí číslo s **menším** exponentem **na větší**. (Nezapomenout na **implicitní 1**) HOW TO: Adding IEEE-754 Floating Point Numbers [[media/szz-09/media/image6.png]]

Odečítání


V CPU lze odečítání realizovat **bitovou negací** jednoho ze sčítanců a použít sčítání s nastavením **C0** na **1**. Stejně tak je výhodné provádět ručně, pro člověka je to přirozenější.

[[media/szz-09/media/image5.png]]

Násobení

- **Celočíselné:** Výsledek může zabírat až **dvojnásobek** bitů. Při násobení čísel v doplňkovém kódu musí být nejdřív u obou čísel **rozsířen MSB** značící znaménko na **dvojnásobnou** přesnost původního čísla ve dvojkovém doplňkovém kódu. 



- **IEEE 754:**
 - **znaménko** výsledku se určí jako **XOR** znamének **činitelů**,
 - **exponent** se určí součtem exponentů činitelů,
 - **mantisa** se určí celočíselným násobením činitelů doplněných o **implicitní 1**.
- Bootovo překódování (Může se také hodit nastudovat.) 

Celočíselné dělení

V počítači velmi náročná operace prováděná mnoha různými metodami. Znaménkové dělení se může provádět s absolutní hodnotou a až poté dojde k doplnění znaménka.

Postupy dělení:

- triviálně na principu **dělení pod sebou**, 
- **bez restaurace nezáporného zbytku**
 1. začne se odečtením dělitele od dělence,
 2. na základě MSB se určí výsledek **i-tého** bitu: pro **MSB=1** je výsledek **0** - záporné číslo, pro **MSB=0** je výsledek **1** - kladné číslo),
 3. dělitel se posune o 1 bit doleva (násobení 2) a **MSB** se **zahodí**,
 4. pokud je výsledek i-tého bitu **0**, **přičte** se dělitel, v **opačném** případě se dělitel **odečte**.
 5. pokud nebylo dosaženo maximálního posuvu, pokračuje se bodem **b**),
 6. na konci může být nutné provést korekci zbytku
- **algoritmem SRT** 

Odkazy:

- How to Convert a Number from Decimal to IEEE 754 Floating Point Representation
 - Video - HOW TO: Convert Decimal to IEEE-754 Single-Precision Binary
- HOW TO: Adding IEEE-754 Floating Point Numbers

Zdroje

- SZZ okruh 9 — studijní materiály FIT BUT (szz-09.docx). Další obrázky: media/szz-09/.

Navigace:  [\[\[index | • Přehled okruhů\]\]](#) ·  [\[\[okruhy/08-minimalizace-logických-vyrazu | 8. Minimalizace logických výrazů\]\]](#) · další: [\[\[okruhy/10-fpga-vhdl | 10. Technologie FPGA\]\]](#) 