

Vyhledávací stromy × paměťová hierarchie (od ADT k disku)

Vyhledávací stromy × paměťová hierarchie

Spojení

Vyvážený vyhledávací strom vypadá v každém okruhu jinak, ale je to **jedna myšlenka (logaritmická hloubka) přeladěná podle toho, kde data leží**:

- **[[okruhy/29-datove-ridici-struktury|okruh 29]]** — binární strom jako **ADT**; vyvažování (AVL, red-black) drží $O(\log n)$ a brání degradaci na seznam.
- **[[okruhy/30-vyhledavani-razeni|okruh 30]]** — **BVS** pro vyhledávání a **stromy s více klíči ve vrcholech (B/B+)**, které snižují výšku.
- **[[okruhy/38-sprava-souboru-pameti|okruh 38]]** — **B+ stromy** jako reálná organizace souborů/DB na disku.

Kde se potkávají

Pojem „mnoho klíčů v jednom uzlu“ se objeví v 30 (zrychlení vyhledávání) i v 38 (uložení na disk) — ale **teprve dohromady dává smysl**: snižování výšky stromu má cenu právě tehdy, když je každý sestup do nižší úrovně drahý.

Průřezový poznatek

Jak se posouváme od RAM k disku, mění se nákladový model a datová struktura se podle toho proměňuje.¹

- V RAM ([[okruhy/04-hierarchie-pameti|okruh 4]]) je náhodný přístup levný □ stačí **binární strom** (vyvážený AVL/red-black).
- Na disku je drahý **blokový I/O** (čtení celého alokačního bloku) □ každý sestup o úroveň = jedno čtení bloku. Proto **B+ strom**: vysoký fan-out (mnoho klíčů/uzel = málo úrovní = málo čtení) a **propojené listy** pro sekvenční průchod.

Otázka „proč mít mnoho klíčů v uzlu“ (okruh 30) má odpověď až ve vrstvě úložiště (okruh 38): **velikost uzlu □ velikost diskového bloku**. Stejně $O(\log n)$, jiná báze logaritmu — a ta báze je tažená paměťovou hierarchií.²

Napětí a kompromisy

- **Výška × šířka uzlu**: binární strom má nejjednodušší uzel, ale nejvíc úrovní; B+ strom platí složitějším uzlem (štěpení/slučování při vkládání/mazání) za méně I/O. Volba závisí na tom, jestli je úzké hrdlo CPU/RAM nebo disk.

¹inferred

²inferred

- **Hašování vs. stromy** (okruh 30): hash tabulka dává $O(1)$ bez uspořádání; strom dává $O(\log n)$, ale **zachovává pořadí** (rozsahové dotazy, sekvenční scan) — proto DB indexy volí B+ strom, ne hash, když potřebují rozsahy.

Otevřené otázky

- Kde přesně leží hranice, za kterou se vyplatí B+ strom místo binárního — jak ji určuje poměr velikosti bloku a velikosti klíče?

Související

- [[okruhy/29-datove-ridici-struktury]]
- [[okruhy/30-vyhledavani-razeni]]
- [[okruhy/38-sprava-souboru-pameti]]
- [[okruhy/04-hierarchie-pameti]]